

Desarrollo matematico del seguimiento de minimos locales para seleccionar suavidad y orden de tendencia

Nota tecnica del proyecto `paper_numerical-smoothness-selection`

Resumen

Esta nota formaliza, paso a paso, el procedimiento exploratorio implementado en `experiments/numerical_smoothness`. La idea central es separar dos tareas. Primero, una perdida de *Validation 1* define la geometria de candidatos: para cada orden de diferencia d , se identifican varios minimos locales de la funcion de perdida en la coordenada de suavidad normalizada $S \in [0, 1]$. Segundo, esos minimos se siguen a traves de ventanas temporales cercanas y cada rama se evalua en un bloque posterior de *Validation 2*. La rama final se escoge por persistencia temporal y desempeno historico en *Validation 2*, no por la misma perdida que la genero. Finalmente, la rama seleccionada se actualiza una vez mas en una *Validation 1* inmediatamente anterior al test, y el test verdadero permanece sin usar hasta el final.

El punto importante es que el valor final de S **no** es un promedio global de suavidades. Es el minimo local mas reciente perteneciente a una rama que ha sido seguida localmente en el tiempo y cuya calidad predictiva fue evaluada fuera de la ventana que genero cada minimo.

Índice

1. Objetivo y notacion	2
2. Suavizador penalizado	3
2.1. Problema de minimos cuadrados penalizados	3
2.2. Coordenada normalizada de suavidad	3
3. Como se continua la tendencia hacia el futuro	4
4. Dos validaciones consecutivas	4
5. Paso 0: seleccionar la longitud de ventana	4
6. Paso 1: inicializar hasta cinco minimos locales	5
7. Paso 2: evaluar cada minimo en Validation 2	5
8. Paso 3: mover la ventana y volver a buscar minimos	5
9. Paso 4: seguimiento local de cada minimo	6
10. Por que el seguimiento local tiene sentido	6
11. Paso 5: almacenar la historia de cada rama	7
12. Paso 6: persistencia de una rama	7

13.Paso 7: score historico de Validation 2	7
14.Paso 8: ultima Validation 1 antes del test	7
15.Paso 9: seleccion de la rama ganadora	8
16.Cual es el smoothness finalmente seleccionado	8
17.Paso 10: refit final y test intacto	9
18.Por que Validation 1 y Validation 2 deben estar separadas	9
19.Interpretacion jerarquica	9
20.Que significa un promedio local de smoothness	10
21.Limitaciones matematicas del tracking actual	10
21.1. Matching greedy	10
21.2. Eleccion de $\varepsilon_{\text{track}}$	10
21.3. Numero variable de minimos	10
21.4. Seleccion de L separada del tracking	11
22.Criterio completo en una sola expresion	11
23.Correspondencia con los archivos del experimento	11
24.Resumen del algoritmo	11
25.Conclusion	12

1. Objetivo y notacion

Sea una serie positiva

$$Y_1, \dots, Y_N, \quad Y_t > 0,$$

y definamos

$$X_t = \log Y_t.$$

En los experimentos aplicados se trabaja sobre X_t . Cuando la metrica de seleccion es `level_rmse`, los pronosticos se transforman de regreso a nivel mediante la exponencial antes de calcular el error.

Los parametros estructurales son:

- $d \in \{1, 2, 3, 4\}$: orden de la penalizacion por diferencias;
- L : longitud de la ventana de entrenamiento;
- h : horizonte de Validation 1, Validation 2 y test final;
- $S \in [0, 1]$: coordenada normalizada de suavidad;
- $\lambda \in [0, \infty]$: parametro clasico de penalizacion;
- $\varepsilon_{\text{track}} > 0$: radio local maximo para continuar un minimo de una ventana a la siguiente.

En el código actual,

$$\varepsilon_{\text{track}} = 0.10,$$

se inicializan como máximo cinco ramas por orden d , y se usa una separación numérica de 0.02 para evitar contar dos veces el mismo mínimo en una misma superficie. Para GDP se usa $h = 8$ trimestres; para SPY, AAPL y BTC-USD se usa $h = 60$ observaciones diarias. El avance de los rolling origins es de una observación para GDP y de cinco observaciones para las series diarias.

2. Suavizador penalizado

2.1. Problema de mínimos cuadrados penalizados

En una ventana de entrenamiento de longitud L , sea

$$\mathbf{x} = (x_1, \dots, x_L)^\top \in \mathbb{R}^L.$$

Sea D_d la matriz de diferencias finitas de orden d . La tendencia penalizada es

$$\hat{\boldsymbol{\tau}}_\lambda = \arg \min_{\boldsymbol{\tau} \in \mathbb{R}^L} \{ \|\mathbf{x} - \boldsymbol{\tau}\|_2^2 + \lambda \|D_d \boldsymbol{\tau}\|_2^2 \}. \quad (1)$$

Definiendo $Q_d = D_d^\top D_d$, la solución es

$$\hat{\boldsymbol{\tau}}_\lambda = H_{\lambda,d} \mathbf{x}, \quad H_{\lambda,d} = (I + \lambda Q_d)^{-1}. \quad (2)$$

Cuando $\lambda = 0$, $H_{0,d} = I$. Cuando $\lambda \rightarrow \infty$, sobreviven únicamente las componentes del null-space:

$$H_{\lambda,d} \longrightarrow P_{\ker(D_d)}.$$

Por tanto, la tendencia límite tiene diferencia d -ésima nula.

2.2. Coordenada normalizada de suavidad

Sea

$$Q_d = U \text{diag}(0, \dots, 0, \delta_1, \dots, \delta_{L-d}) U^\top, \quad \delta_j > 0.$$

La coordenada usada en el paper y en el código es

$$S(\lambda; L, d) = 1 - \frac{1}{L-d} \sum_{j=1}^{L-d} \frac{1}{1 + \lambda \delta_j}. \quad (3)$$

Entonces

$$S(0) = 0, \quad S(\infty) = 1,$$

y

$$\frac{\partial S}{\partial \lambda} = \frac{1}{L-d} \sum_{j=1}^{L-d} \frac{\delta_j}{(1 + \lambda \delta_j)^2} > 0. \quad (4)$$

Por tanto, S y λ ordenan los modelos de la misma manera, pero S vive en el intervalo compacto $[0, 1]$. Escribimos

$$\lambda = \lambda(S; L, d)$$

para la inversa numérica de (3).

3. Como se continua la tendencia hacia el futuro

El pronostico no es un polinomio ajustado por una regresion separada del suavizador. Se toma la tendencia penalizada al final de la ventana y se continua imponiendo

$$\Delta^d \hat{\tau}_t = 0 \quad \text{para los puntos futuros.} \quad (5)$$

La recurrencia usada por el codigo es

$$\hat{\tau}_{n+1} = - \sum_{k=0}^{d-1} (-1)^{d-k} \binom{d}{k} \hat{\tau}_{n-d+1+k}. \quad (6)$$

Esto produce una continuacion constante para $d = 1$, lineal para $d = 2$, cuadratica para $d = 3$ y cubica para $d = 4$, en el sentido de diferencias finitas. Por eso d determina tambien la geometria de la extrapolacion.

4. Dos validaciones consecutivas

Para un rolling origin r , usamos tres bloques consecutivos:

$$\boxed{\mathcal{T}_r} \longrightarrow \boxed{\mathcal{V}_r^{(1)}} \longrightarrow \boxed{\mathcal{V}_r^{(2)}},$$

con

$$|\mathcal{T}_r| = L, \quad |\mathcal{V}_r^{(1)}| = |\mathcal{V}_r^{(2)}| = h.$$

Validation 1 descubre la geometria local de candidatos. Validation 2 mide si cada candidato sigue funcionando en el bloque temporal inmediatamente posterior.

Para S , sea

$$\hat{\mathbf{z}}_{r,d,L,h}^{(1)}(S)$$

el forecast de Validation 1 y $\mathbf{z}_r^{(1)}$ su valor observado. La perdida es

$$F_{r,d,L,h}^{(1)}(S) = \frac{1}{h} \left\| \mathbf{z}_r^{(1)} - \hat{\mathbf{z}}_{r,d,L,h}^{(1)}(S) \right\|_2^2. \quad (7)$$

La funcion $S \mapsto F_{r,d,L,h}^{(1)}(S)$ puede tener varios minimos locales.

5. Paso 0: seleccionar la longitud de ventana

Antes de seguir ramas, el codigo escoge una sola longitud L para cada orden d . Sea $\mathcal{R}_{d,L}$ el conjunto de rolling origins historicos para los que caben Validation 1 y Validation 2 completas. Se define

$$\overline{F}_{d,L}^{(1)}(S) = \frac{1}{|\mathcal{R}_{d,L}|} \sum_{r \in \mathcal{R}_{d,L}} F_{r,d,L,h}^{(1)}(S). \quad (8)$$

Para cada L , sea

$$\hat{S}_{d,L}^{\text{agg}} \in \arg \min_{S \in \mathcal{C}_{d,L}^{\text{agg}}} \overline{F}_{d,L}^{(1)}(S),$$

donde $\mathcal{C}_{d,L}^{\text{agg}}$ contiene los minimos recuperados y los endpoints relevantes. Entonces

$$L_d^* = \arg \min_L \overline{F}_{d,L}^{(1)}(\hat{S}_{d,L}^{\text{agg}}). \quad (9)$$

Este paso no escoge todavia el smoothness final. Solo fija la escala temporal sobre la cual se seguiran los minimos.

6. Paso 1: inicializar hasta cinco minimos locales

Fijados d y L_d^* , en el primer rolling origin se define

$$\mathcal{M}_{d,1} = \left\{ S \in (0, 1) : \frac{\partial F_{1,d,L_d^*,h}^{(1)}}{\partial S}(S) = 0, \quad \frac{\partial^2 F_{1,d,L_d^*,h}^{(1)}}{\partial S^2}(S) > 0 \right\}, \quad (10)$$

mas los endpoints que actuan como minimos de frontera.

Se deduplican soluciones a menos de 0.02 en la escala S . Si hay mas de cinco, se conservan los cinco con menor perdida de Validation 1:

$$S_{d,1,1}, \dots, S_{d,J_d,1}, \quad J_d \leq 5.$$

Cada uno inicia una rama $\mathcal{B}_{d,j}$.

7. Paso 2: evaluar cada minimo en Validation 2

Para cada $S_{d,j,r}$, Validation 1 ya fue utilizada para descubrir el candidato. Para evaluarlo predictivamente, el modelo se refitea usando todos los datos disponibles hasta el final de Validation 1, manteniendo

$$d, \quad L_d^*, \quad S_{d,j,r}$$

fijos. Sea $\hat{z}_{d,j,r}^{(2)}$ el forecast del siguiente bloque.

La metrica default es RMSE en nivel:

$$E_{d,j,r}^{(2)} = \sqrt{\frac{1}{h} \sum_{\ell=1}^h \left(Y_{r,\ell}^{(2)} - \hat{Y}_{d,j,r,\ell}^{(2)} \right)^2}. \quad (11)$$

Tambien se guarda RMSE en log-escala:

$$E_{d,j,r}^{(2,\log)} = \sqrt{\frac{1}{h} \sum_{\ell=1}^h \left(X_{r,\ell}^{(2)} - \hat{X}_{d,j,r,\ell}^{(2)} \right)^2}. \quad (12)$$

La separacion conceptual es

$$\boxed{F^{(1)} \text{ genera candidatos}} \quad \text{y} \quad \boxed{E^{(2)} \text{ juzga su utilidad futura}}.$$

8. Paso 3: mover la ventana y volver a buscar minimos

Avanzamos el rolling origin una cantidad pequena q . En el codigo, $q = 1$ para GDP y $q = 5$ para las series diarias. Se vuelve a construir

$$F_{r+1,d,L_d^*,h}^{(1)}(S)$$

y se recupera su conjunto de minimos locales

$$\mathcal{M}_{d,r+1}.$$

La hipotesis operativa es que, si la ventana cambia poco, un minimo local bien definido deberia moverse poco en S .

9. Paso 4: seguimiento local de cada minimo

Supongamos que la rama j tenia ultimo minimo conocido $S_{d,j,r}$. Un candidato $\tilde{S} \in \mathcal{M}_{d,r+1}$ puede continuar esa rama solo si

$$|\tilde{S} - S_{d,j,r}| \leq \varepsilon_{\text{track}}. \quad (13)$$

Entre todos los pares rama-candidato se consideran las distancias

$$D_{jk} = |S_{d,j,r} - \tilde{S}_{d,k,r+1}|.$$

El codigo ordena los pares por distancia y realiza una asignacion greedy uno-a-uno: toma primero el par mas cercano permitido, despues el siguiente que no reutilice ni la rama ni el candidato, y asi sucesivamente.

La regla implementada aproxima

$$S_{d,j,r+1} \approx \arg \min_{\tilde{S} \in \mathcal{M}_{d,r+1}} |\tilde{S} - S_{d,j,r}| \quad \text{sueto a} \quad |\tilde{S} - S_{d,j,r}| \leq \varepsilon_{\text{track}}, \quad (14)$$

con correspondencia uno-a-uno entre ramas y minimos nuevos.

Si ninguna raiz nueva cae dentro del radio permitido, se registra

$$\text{status} = \text{extttmissing_local_minimum}.$$

No se sustituye automaticamente por el mejor minimo global. La rama conserva como referencia su ultimo S exitosamente observado y puede reaparecer mas adelante si vuelve a existir un minimo dentro del vecindario local.

10. Por que el seguimiento local tiene sentido

Imaginemos provisionalmente que el origen temporal puede representarse por un parametro continuo u . Sea $F(S, u)$ la perdida de Validation 1 cuando la ventana esta localizada alrededor de u . Supongamos que

$$F_S(S_0, u_0) = 0, \quad F_{SS}(S_0, u_0) > 0.$$

Si F es suficientemente suave y la curvatura no se anula, el teorema de la funcion implicita da una trayectoria local $S^*(u)$ con

$$F_S(S^*(u), u) = 0,$$

y

$$\frac{dS^*(u)}{du} = -\frac{F_{Su}(S^*(u), u)}{F_{SS}(S^*(u), u)}. \quad (15)$$

Por tanto, si la ventana cambia poco, el termino cruzado no es excesivamente grande y la curvatura permanece separada de cero,

$$S^*(u + \delta) \approx S^*(u) + O(\delta).$$

La condicion (13) es una version discreta de esta idea de continuacion de soluciones.

Tambien explica por que no conviene promediar globalmente minimos de cuencas distintas. Si dos ramas persistentes estan cerca de 0.10 y 0.90, su media es 0.50, pero nada garantiza que 0.50 sea un minimo. El objeto relevante es cada trayectoria local

$$\mathcal{B}_{d,j} = (S_{d,j,1}, S_{d,j,2}, \dots).$$

11. Paso 5: almacenar la historia de cada rama

Para cada rolling origin y rama se guarda

$$S_{d,j,r}, \quad F_{r,d,L_d^*,h}^{(1)}(S_{d,j,r}), \quad E_{d,j,r}^{(2)}$$

junto con

$$\Delta S_{d,j,r} = |S_{d,j,r} - S_{d,j,r-1}|.$$

Tambien se guarda el numero total de minimos de la superficie,

$$M_{d,r} = |\mathcal{M}_{d,r}|,$$

el numero de ramas emparejadas, las fechas exactas de ambos bloques y el forecast completo sobre Validation 2.

12. Paso 6: persistencia de una rama

Sea $R_{d,j}$ el numero total de rolling origins considerados para la rama j , y sea $R_{d,j}^{\text{match}}$ el numero de origins en que se encontro una continuacion local. La fraccion de soporte es

$$P_{d,j} = \frac{R_{d,j}^{\text{match}}}{R_{d,j}}. \quad (16)$$

Una rama con $P_{d,j} = 1$ persistio en todos los origins historicos. Esta cantidad actua como regularizacion de estabilidad: una rama con un RMSE ocasionalmente bajo pero que desaparece con frecuencia no se trata igual que una rama que puede seguirse coherentemente.

13. Paso 7: score historico de Validation 2

Para cada rama se promedian unicamente los scores de los origins en los que la rama fue emparejada. Con la metrica default,

$$A_{d,j} = \frac{1}{R_{d,j}^{\text{match}}} \sum_{r: (d,j) \text{ existe en } r} E_{d,j,r}^{(2)}. \quad (17)$$

Con `-selection-metric log_rmse` se reemplaza $E^{(2)}$ por $E^{(2,\log)}$.

14. Paso 8: ultima Validation 1 antes del test

Toda la historia usada para tracking termina antes de los ultimos $2h$ puntos. La estructura final es

$$\boxed{\text{historia para tracking}} \longrightarrow \boxed{\mathcal{V}_{\text{final}}^{(1)}} \longrightarrow \boxed{\mathcal{T}_{\text{test}}},$$

donde los dos ultimos bloques tienen longitud h .

En $\mathcal{V}_{\text{final}}^{(1)}$ se construye una ultima superficie de Validation 1 para cada d . Cada rama historica se intenta continuar una vez mas:

$$S_{d,j,\text{final}} = \arg \min_{S \in \mathcal{M}_{d,\text{final}}} |S - S_{d,j,\text{last}}| \quad \text{sueto a} \quad |S - S_{d,j,\text{last}}| \leq \varepsilon_{\text{track}}. \quad (18)$$

Una rama que no puede continuar hasta esta superficie final no es elegible para el forecast final.

15. Paso 9: seleccion de la rama ganadora

Sea $\mathcal{J}_{\text{final}}$ el conjunto de ramas que pudieron continuar hasta la superficie final. El codigo aplica primero una regla de persistencia.

Si existe al menos una rama con $P_{d,j} = 1$, el conjunto elegible es

$$\mathcal{E} = \{(d, j) \in \mathcal{J}_{\text{final}} : P_{d,j} = 1\}. \quad (19)$$

Si ninguna tiene soporte completo, sea

$$P_{\text{máx}} = \max_{(d,j) \in \mathcal{J}_{\text{final}}} P_{d,j},$$

y

$$\mathcal{E} = \{(d, j) \in \mathcal{J}_{\text{final}} : P_{d,j} = P_{\text{máx}}\}. \quad (20)$$

Dentro de ese conjunto, la rama ganadora es

$$(d^*, j^*) = \arg \min_{(d,j) \in \mathcal{E}} A_{d,j}. \quad (21)$$

En caso de empate numerico, la implementacion actual rompe el empate por d y despues por el identificador de rama. La regla puede resumirse como

persistencia primero + menor perdida historica en Validation 2.

16. Cual es el smoothness finalmente seleccionado

Una vez seleccionada la rama (d^*, j^*) , el smoothness utilizado para el forecast final es

$S_{\text{final}}^* = S_{d^*, j^*, \text{final}}.$

(22)

Es decir:

- no es el S del primer rolling origin;
- no es el minimo global de todas las superficies historicas;
- no es el promedio de todos los S ;
- no usa el test verdadero;
- es el minimo local actual de la rama historicamente seleccionada.

La rama se escoge por su comportamiento historico en Validation 2, pero su posicion final se actualiza localmente con la informacion mas reciente disponible antes del test.

17. Paso 10: refit final y test intacto

Sea $L^* = L_{d^*}^*$. Tomamos las ultimas L^* observaciones disponibles antes del test, incluyendo el bloque final de Validation 1, y ajustamos

$$\hat{\tau}_{\text{final}} = \arg \min_{\tau} \{ \|\mathbf{x}_{\text{final}} - \tau\|_2^2 + \lambda(S_{\text{final}}^*) \|D_{d^*} \tau\|_2^2 \}. \quad (23)$$

Despues se continua esa tendencia h pasos usando

$$\Delta^{d^*} \hat{\tau}_t = 0.$$

Solo entonces se compara con el test real.

El test no participa en la seleccion de L , deteccion de minimos, tracking, score historico $A_{d,j}$, eleccion de rama ni seleccion de S_{final}^* . Solo produce metricas retrospectivas de diagnostico.

18. Por que Validation 1 y Validation 2 deben estar separadas

Si el mismo bloque que define $S_{d,j,r}$ tambien se utilizara para decidir cual minimo es predictivamente mejor, la seleccion reutilizaria la misma realizacion que genero los candidatos.

Aqui,

$$\mathcal{V}^{(1)} : \text{descubrimiento geometrico}, \quad \mathcal{V}^{(2)} : \text{evaluacion temporal posterior}.$$

Puede ocurrir que

$$F^{(1)}(S_a) < F^{(1)}(S_b)$$

pero

$$E^{(2)}(S_a) > E^{(2)}(S_b).$$

Ese desacuerdo es justamente informacion util: dos minimos de la misma superficie pueden tener capacidad de continuacion muy diferente.

19. Interpretacion jerarquica

El metodo puede verse como

$$d \rightarrow L_d^* \rightarrow \text{ramas locales de } S \rightarrow \text{persistencia} \rightarrow \text{Validation 2} \rightarrow S_{\text{final}}^*.$$

Cada etapa controla un aspecto distinto:

- d determina la familia geometrica de extrapolacion;
- L determina la escala temporal de entrenamiento;
- los minimos locales de S representan escalas de suavidad competitivas;
- el tracking conserva la identidad de esas escalas a traves del tiempo;
- la persistencia penaliza soluciones temporalmente fragiles;
- Validation 2 mide utilidad predictiva posterior;
- la ultima Validation 1 actualiza la posicion de la rama antes del test.

Una rama no es una distribucion posterior ni un intervalo de confianza. Es una trayectoria determinista de minimos locales de problemas de optimizacion cercanos.

20. Que significa un promedio local de smoothness

El codigo actual no usa un promedio de S para el forecast final: usa (22). Sin embargo, una extension coherente seria promediar *solo dentro de la misma rama y localmente en el tiempo*. Por ejemplo,

$$\tilde{S}_{d,j,R}^{(K)} = \frac{1}{K} \sum_{k=0}^{K-1} S_{d,j,R-k}, \quad (24)$$

o una media ponderada

$$\tilde{S}_{d,j,R}^{(\rho)} = \frac{\sum_{k=0}^{K-1} \rho^k S_{d,j,R-k}}{\sum_{k=0}^{K-1} \rho^k}, \quad 0 < \rho \leq 1. \quad (25)$$

Esto es muy distinto de promediar minimos de cuencas diferentes. En (24), todos los terminos ya fueron identificados como la misma rama mediante (13). El codigo reporta medias y medianas globales y de los cinco matches mas recientes por rama para diagnostico, pero el default actual usa el minimo local mas reciente.

21. Limitaciones matematicas del tracking actual

21.1. Matching greedy

La asignacion rama–minimo es greedy por distancia. Si dos ramas se acercan o cruzan, la correspondencia puede depender del orden de las distancias. Una alternativa mas formal seria resolver

$$\min_{\pi} \sum_j |S_{d,j,r} - \tilde{S}_{d,\pi(j),r+1}| \quad (26)$$

sujeto a

$$|S_{d,j,r} - \tilde{S}_{d,\pi(j),r+1}| \leq \varepsilon_{\text{track}},$$

por ejemplo con Hungarian matching. El codigo actual usa la aproximacion greedy.

21.2. Eleccion de $\varepsilon_{\text{track}}$

El radio 0.10 es una regla operativa, no un parametro inferido estadisticamente. Si es demasiado pequeno, una rama puede fragmentarse; si es demasiado grande, dos cuencas pueden confundirse. Por ello conviene inspeccionar

$$\max_r |S_{d,j,r+1} - S_{d,j,r}|,$$

la distribucion de ΔS , el numero de minimos por superficie y el numero de matches por origen.

21.3. Numero variable de minimos

No se impone que

$$|\mathcal{M}_{d,r}| = |\mathcal{M}_{d,r+1}|.$$

Que el numero permanezca estable es una hipotesis empirica que puede examinarse en `rolling_minimum_tracks.cs` y en el dashboard. El nacimiento, desaparicion o fusion aparente de minimos puede ser informacion relevante.

21.4. Selecccion de L separada del tracking

L_d^* se selecciona una vez por orden mediante la perdida agregada de Validation 1. No se sigue una trayectoria temporal de L . Una extension mayor podria seguir simultaneamente ramas en (L, S) , pero seria un problema de correspondencia bidimensional distinto.

22. Criterio completo en una sola expresion

Aunque el procedimiento es secuencial, puede resumirse como

$$(d^*, j^*) = \arg \min_{(d,j)} \{A_{d,j} : (d, j) \text{ es suficientemente persistente y continua al origen final}\}, \quad (27)$$

donde

$$A_{d,j} = \frac{1}{R_{d,j}^{\text{match}}} \sum_r E_{d,j,r}^{(2)},$$

y la secuencia $\{S_{d,j,r}\}_r$ satisface

$$S_{d,j,r} \in \mathcal{M}_{d,r}, \quad |S_{d,j,r} - S_{d,j,r-1}| \leq \varepsilon_{\text{track}}.$$

Despues,

$$S_{\text{final}}^* = \text{continuacion local final de la rama } (d^*, j^*).$$

Por eso el metodo no selecciona simplemente un numero S : selecciona una **rama estable de soluciones locales** y usa su estado mas reciente.

23. Correspondencia con los archivos del experimento

Archivo	Objeto matematico principal
order_window_selection.csv	L_d^* y la perdida agregada de Validation 1
rolling_minimum_tracks.csv	$S_{d,j,r}$, $F_{d,j,r}^{(1)}$, $E_{d,j,r}^{(2)}$, $\Delta S_{d,j,r}$, soporte y conteo de minimos
rolling_validation_paths.csv	$\hat{z}_{d,j,r}^{(2)}$ completo para cada rama y origen
tracked_branch_selection.csv	$P_{d,j}$, $A_{d,j}$, resúmenes de S , continuidad final y rama ganadora
tracked_branch_test_paths.csv	pronostico final de cada rama que pudo continuar
run_metadata.json	protocolo, parametros, hashes y rol del test

24. Resumen del algoritmo

Para cada serie:

1. Reservar el test final de longitud h .
2. Para cada d , escoger L_d^* por (9).
3. En el primer rolling origin, encontrar hasta cinco minimos locales de Validation 1.
4. Inicializar una rama por minimo.

5. Evaluar cada rama en Validation 2.
6. Mover el rolling origin y reconstruir la superficie de Validation 1.
7. Continuar cada rama al minimo nuevo mas cercano dentro de $\varepsilon_{\text{track}}$, sin reutilizar minimos.
8. Repetir y acumular $E_{d,j,r}^{(2)}$.
9. Calcular soporte $P_{d,j}$ y score historico $A_{d,j}$.
10. Construir una ultima Validation 1 inmediatamente antes del test.
11. Continuar localmente cada rama una vez mas.
12. Elegir la rama mas persistente y, entre las elegibles, la de menor $A_{d,j}$.
13. Usar su nuevo minimo local como S_{final}^* .
14. Refit final y forecast del test verdadero.

En simbolos:

$$F_r^{(1)}(S) \rightarrow \mathcal{M}_r \rightarrow S_{j,r} \rightarrow E_{j,r}^{(2)} \rightarrow S_{j,r+1} \rightarrow E_{j,r+1}^{(2)} \rightarrow \dots$$

y finalmente

$$\{E_{j,r}^{(2)}\}_r \rightarrow j^* \rightarrow S_{\text{final}}^* \rightarrow \text{true test}.$$

25. Conclusion

El procedimiento separa tres ideas que conviene no mezclar:

geometria de la perdida $\longrightarrow$ persistencia de un minimo local $\longrightarrow$ calidad predictiva posterior.

Validation 1 crea los candidatos; el rolling temporal los convierte en ramas; Validation 2 asigna a cada rama una historia de desempeno fuera de la ventana que genero el minimo. La rama ganadora debe ser suficientemente persistente y tener el menor score historico de Validation 2 entre las ramas elegibles. El smoothness final es su minimo local mas reciente:

$$\boxed{S_{\text{final}}^* = S_{d^*,j^*,\text{final}}.}$$

Esta construccion tiene sentido porque conserva la identidad de cada cuenca de optimizacion, evita promediar soluciones que pertenecen a minimos diferentes y separa el descubrimiento de candidatos de su evaluacion predictiva. El test verdadero permanece fuera de todo el proceso de seleccion.